Технологии глубокого обучения и нейронных сетей

Лекция 2

Устройство трансформера

Петр Георгиевич Меньших · МТУСИ

Модель — семейство распределений.

Обучение — выбор члена семейства, при котором данные наиболее правдоподобны.

Дальше меняется только богатство семейства и масштаб данных.

Все, что мы будем изучать, от бустинга до GPT, укладывается в эти три предложения.

Что упоминалось на первой лекции

1. Как слово становится вектором
2. Что за список токенов и откуда он взялся
3. Почему не рекуррентные сети
4. Что такое внимание
5. Почему модель теряет требование на длинной задаче

Это и есть план пары.

Модель видит номера

ВРАЧ ОСМОТРЕЛ ПАЦИЕНТА

В	ра	ч	ос	мотр	ел	паци	ента

восемь токенов, каждый это номер в списке из 151 936

Слов бесконечно много

Формы, опечатки, имена, новые термины. Любой список слов завтра встретит слово, которого в нем нет.

У русского морфология

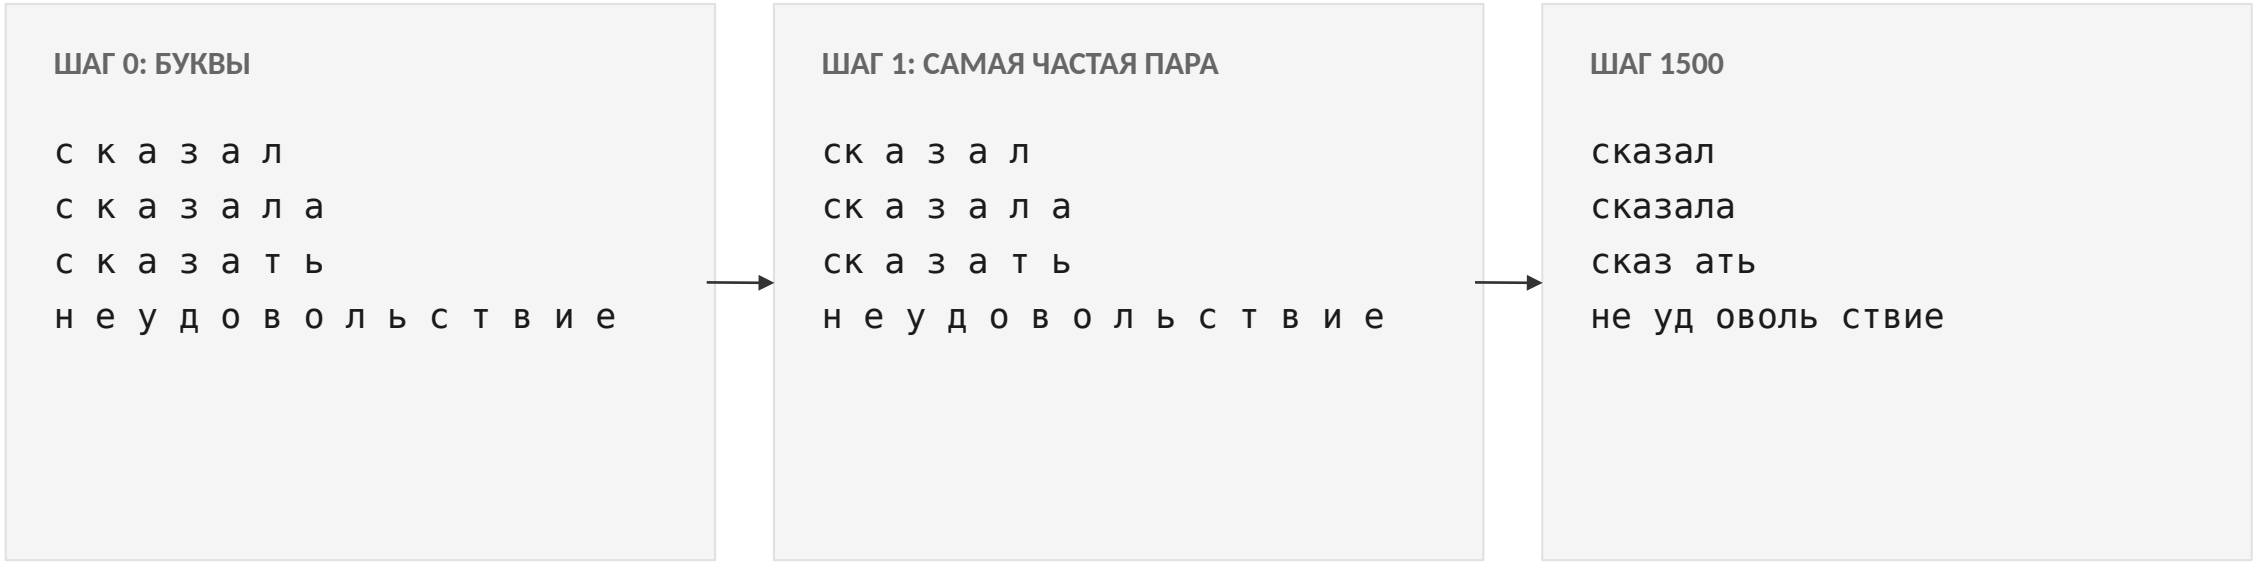
«Сказал, сказала, сказали, скажет, скажи»: пять записей в списке слов при одном смысле.

Байты слишком мелко

Страница текста это четыре тысячи шагов по одной букве. На смысл сил не остается.

Токен это компромисс: частое слово целиком, редкое кусками, незнакомое из букв.

Откуда берется список: BPE (Byte Pair Encoding)



Склеить самую частую пару соседних символов, повторить. Число склеиваний это размер словаря.

Словарь не придумывается, а формируется из букв по частоте.
У Qwen3 около 150 тысяч токенов, а у BPE в лабораторной 1500.

Стоимость в токенах

ОДНА И ТА ЖЕ ФРАЗА

В	ра	ч	ос	мотр	ел	паци	ента	и	сказал	,	что	его	ана	ли	зы	готов	ы	.

19 токенов

The	doctor	examined	the	patient	and	said	that	his	tests	were	ready	.

13 токенов

РУССКИЙ, АБЗАЦ В 100 СЛОВ

1.98 токена на слово

в контекст на 4096 токенов помещается около 2 тысяч слов

АНГЛИЙСКИЙ, АБЗАЦ В 70 СЛОВ

1.16 токена на слово

в контекст на 4096 токенов помещается около 3.5 тысяч слов

Контекст и цена измеряются в токенах, а не в словах. LLM-сервис обязан их считать.

Токен в вектор

ТОКЕН	1024 ЧИСЛА, ПОДОБРАНЫ ПРИ ОБУЧЕНИИ
…	…
врач	0.12 −0.80 0.33 0.05 …
ключ	−0.41 0.22 0.07 −0.63 …
король	0.58 0.14 −0.29 0.91 …
королева	0.55 0.11 −0.25 0.88 …
…	…

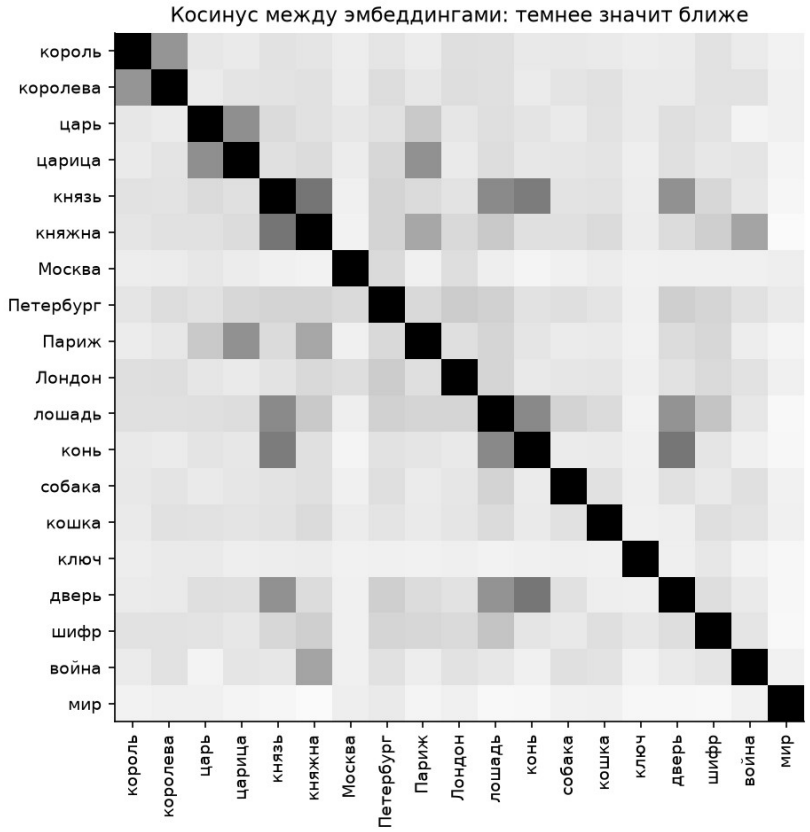
Эмбеддинг это строка таблицы.

Строк столько, сколько токенов в списке. Номер токена это номер строки.

Числа условные. Настоящие ничего не скажут глазу, у них одно полезное свойство: на следующем слайде.

Взяли строку, вот и вектор. Больше в превращении номера в вектор ничего нет.

Близкие по смыслу рядом



Близость векторов означает похожесть.

Модель не знает, что такое король. Но «король» встречается там же, где «королева», «царь» там же, где «царица», и векторы сдвинулись друг к другу.

Те же эмбеддинги, что в карте классики росли из PCA. И те же, что в RAG ищут похожие куски документов.

Косинус между строками таблицы эмбеддингов Qwen3-0.6B: темнее значит ближе. «Князь» рядом с «конем» это уже не смысл: вектор слова из кусков это среднее кусков, и совпавшие куски тоже сближают.

Одна проблема и одна метка

ключ от двери

ключ к шифру

один номер, одна строка таблицы, один вектор

Вектор токена одинаков в любом контексте.

Каждое слово должно вобрать в себя соседей. Это задача на остаток лекции.

И ОДНА МЕТКА

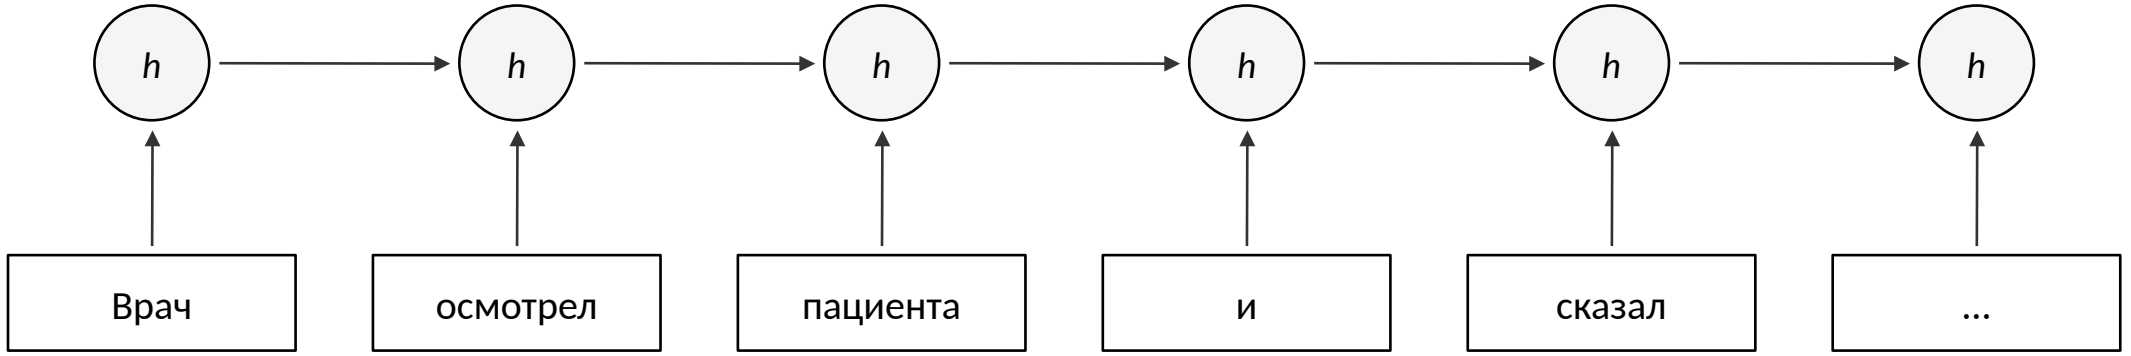
«собака укусила человека»
«человек укусил собаку»

Без порядка это один мешок векторов. К каждому вектору добавляется метка позиции. У современных моделей она называется RoPE.

На входе в модель у каждого токена есть вектор смысла и метка места. Дальше вопрос, как слову вобрать в себя соседей.

Рекуррентная сеть

СОСТОЯНИЕ h ПЕРЕДАЕТСЯ ПО ЦЕПОЧКЕ, СЛОВА ВХОДЯТ ПО ОДНОМУ



Читает слово за словом и несет один вектор состояния. Сотое слово знает о первом только то, что дошло через девяносто девять пересказов.

Пересказ по цепочке. Так делали до 2017 года: RNN, LSTM, первый приличный машинный перевод.

Две проблемы

Не умещается

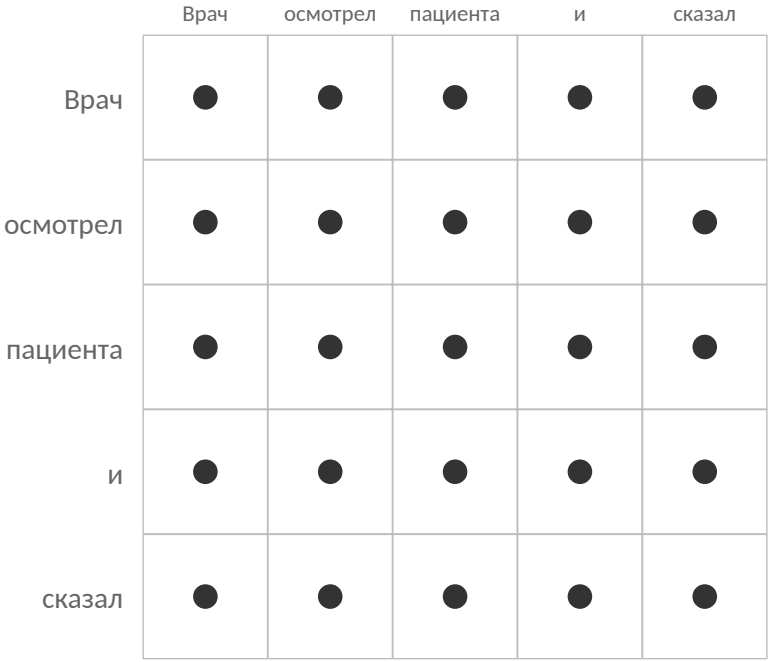
Все, что было сто слов назад, должно влезть в один вектор фиксированного размера. Теряется в первую очередь далекое: кто был слепым в начале абзаца, к концу абзаца уже неизвестно.

Не параллелится

Слово номер сто ждет слова номер девяносто девять. Видеокарта умеет тысячи одинаковых операций разом и почти не умеет по очереди. Самое дорогое железо работает на проценты.

Первая проблема про качество, вторая про скорость и деньги.
Вторая оказалась важнее: обучать стало невозможно долго.

Решение



строка: кто смотрит · столбец: на кого

Каждое слово смотрит на все остальные напрямую, без пересказа.

И все это считается одновременно: ни одно слово не ждет другого.

2017 год, «Attention is all you need». Из архитектуры выбросили цепочку и оставили только механизм, где каждый смотрит на каждого.

Это и есть внимание. «Пересказ по цепочке» вспомним в конце пары.

Библиотека без каталога

Что ищу *Query*

Запрос в голове читателя: «книга про то, как коптить рыбу».

Как меня найти *Key*

Аннотация на корешке: «рыбалка на Волге», «домашнее копчение», «история флота».

Что отдаю *Value*

Содержимое книги, то, что читатель унесет в конспект.

Читатель сравнивает запрос с каждой аннотацией и составляет конспект из всех книг, пропорционально совпадению.

В модели каждый токен одновременно и читатель, и книга. Каждый спрашивает у всех, каждый отвечает всем.

Четыре шага

ВЕКТОР ТОКЕНА	строка таблицы плюс метка позиции
↓	
ТРИ ВЕКТОРА ТРЕМЯ МАТРИЦАМИ	запрос · ключ · значение
↓	
ОЦЕНКИ	запрос сравнивается с ключами всех токенов
↓	
ДОЛИ	softmax: тот же, что на первой лекции, в сумме единица
↓	
НОВЫЙ ВЕКТОР ТОКЕНА	взвешенная сумма значений, теперь с контекстом

Почему матрицы три, а не одна

Если запрос и ключ это один вектор, каждый токен лучше всего совпадает сам с собой, и внимание сводится к «смотри на себя».

Три разные матрицы позволяют слову искать не себя, а то, что ему нужно: «его» ищет существительное слева.

Числовой пример

ЗАПРОС ПЕРВОГО ТОКЕНА

$q_1 = (1, 0)$

КЛЮЧИ ТРЕХ ТОКЕНОВ

$k_1 = (1, 0)$
$k_2 = (0, 1)$
$k_3 = (0.7, 0.7)$

ЗНАЧЕНИЯ ТРЕХ ТОКЕНОВ

$v_1 = (2, 0)$
$v_2 = (0, 2)$
$v_3 = (1, 1)$

ОЦЕНКИ $q_1 \cdot k_j$

1
0
0.7

$$\text{softmax}(1,\ 0,\ 0.7) = (0.47,\ 0.17,\ 0.35)$$

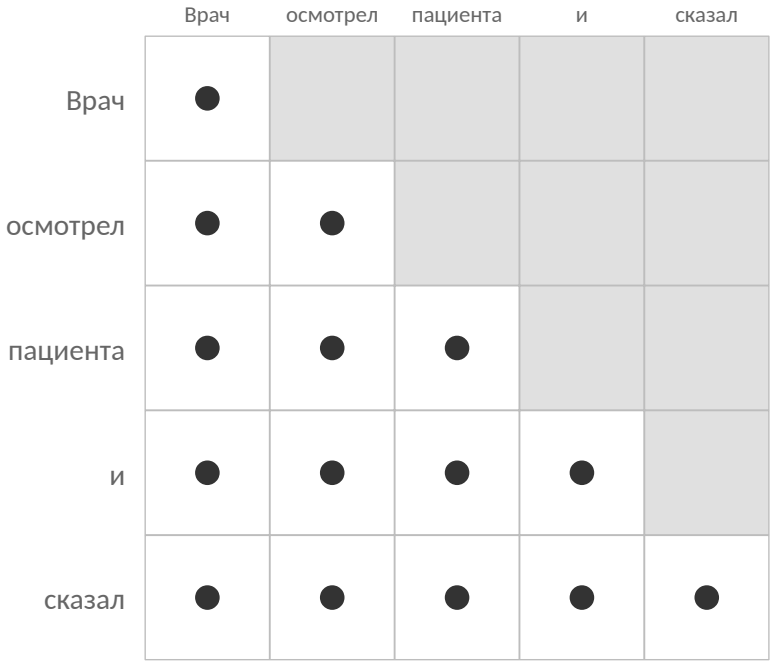
ноль не стал нулем: softmax подавляет, а не выкидывает

ВЗВЕШЕННАЯ СУММА ЗНАЧЕНИЙ С ЭТИМИ ДОЛЯМИ

$$0.47 \cdot (2, 0) + 0.17 \cdot (0, 2) + 0.35 \cdot (1, 1) = (1.29, 0.69)$$

Это новый вектор первого токена: 47 процентов от себя, 35 от третьего, 17 от второго.

Маска



серое запрещено

Токен видит только себя и то, что слева.

Модель учится предсказывать следующее слово. Если бы при обучении третье слово видело четвертое, оно бы подсмотрело ответ.

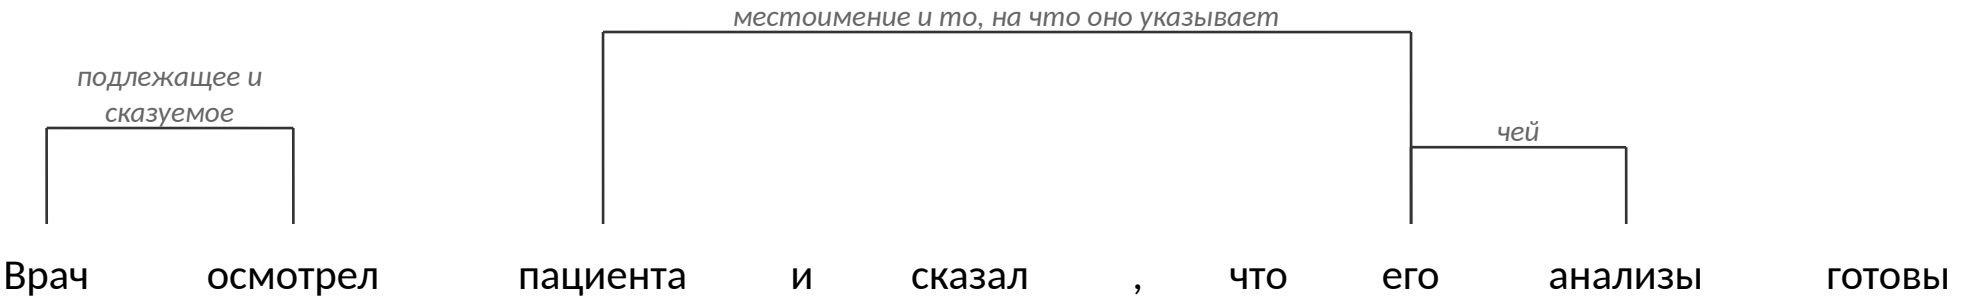
В оценки ставится минус бесконечность, после softmax эти доли ровно ноль. Модели с такой маской называются декодерами.

Из маски растет кэш: ключи и значения старых токенов не меняются, их считают один раз. Лекция про продакшн.

Половина таблицы запрещена, потому что иначе учиться было бы нечему.

Головы

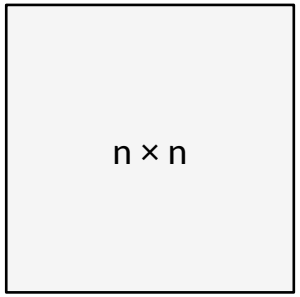
ОДНО ВНИМАНИЕ ЛОВИТ ОДНУ СВЯЗЬ, А СВЯЗЕЙ МНОГО



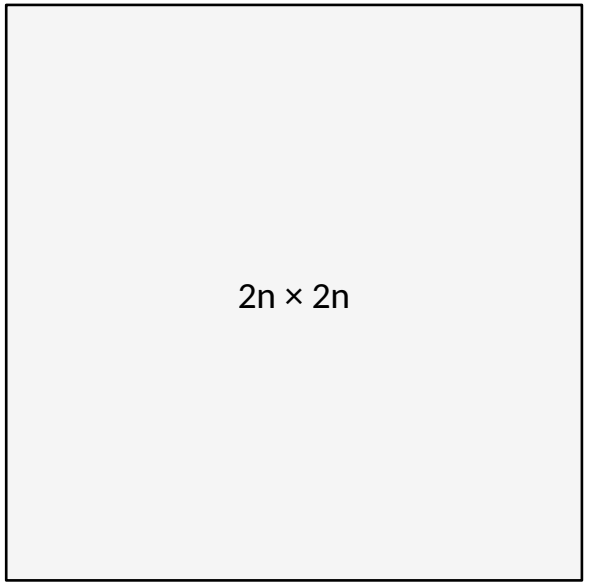
Наборов матриц несколько: у Qwen3-0.6B шестнадцать, у больших моделей до 128. Каждый набор называется головой, результаты склеиваются.

Никто не говорит голове, за чем следить. На демо увидим, что они специализируются сами.

Цена



контекст n



контекст 2n: работы в четыре раза больше

Каждый токен сравнивается с каждым.

Удвоили длину контекста, учетверили работу внимания. Так же растет память под таблицу долей.

Отсюда дорогой длинный контекст, кэш и хитрые виды внимания. Это материалы лекции про продакшн.

Отсюда предел на длину контекста: что не влезло, выбрасывается. Одна из двух причин потери требования во «Вскрытии».

Формула

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right)V$$

$Q\,K^T$

оценки: запросы против ключей, все сразу

softmax

оценки в доли, по строке

V

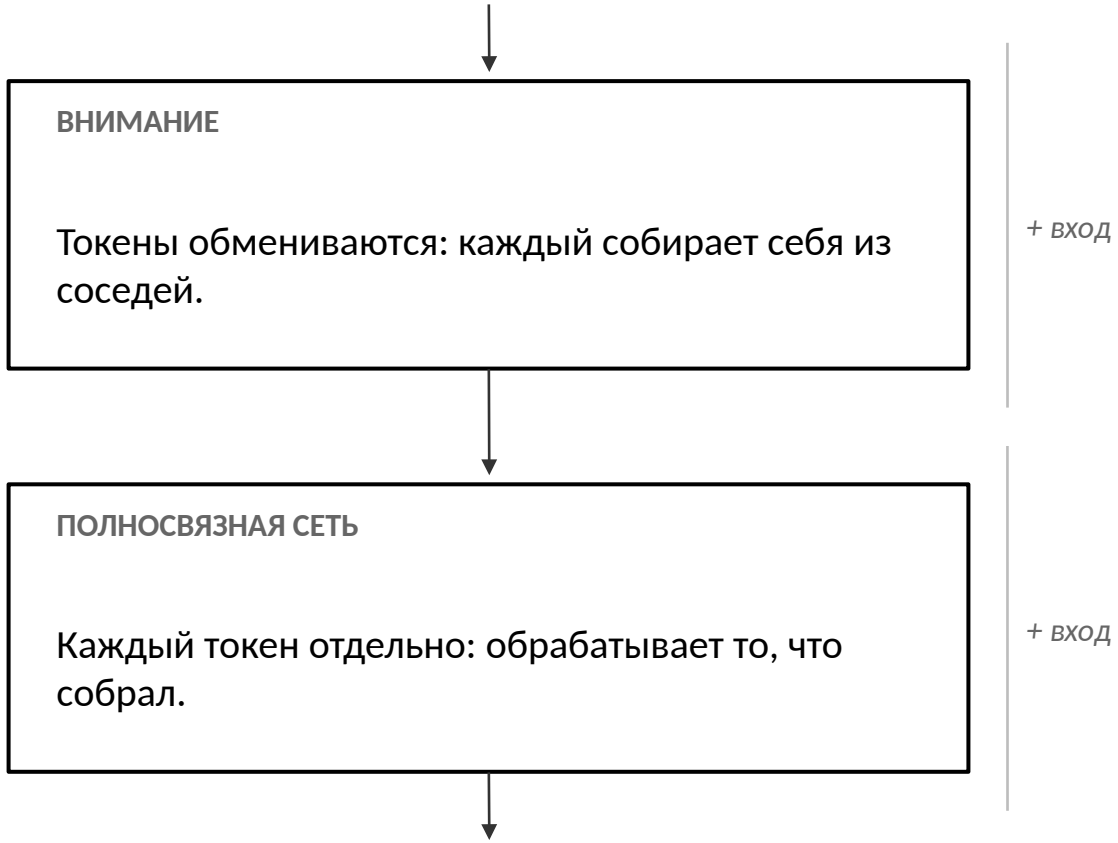
значения с долями

√d

техническая поправка, чтобы оценки не улетали

Те же четыре шага. Не разбираем, но узнавать нужно. Матрицы, размерности и корень в заметке lectures/02/why-attention.md.

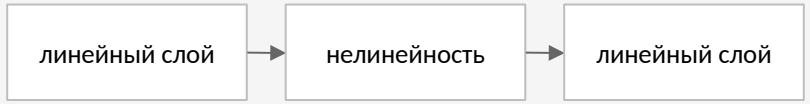
Слой трансформера



Один слой это два блока подряд.

Внимание это обмен, полносвязная сеть это обработка. К выходу каждого блока прибавляется его вход, чтобы сигнал не терялся в глубине.

ТА ЖЕ СЕТЬ, ЧТО НА СЛАЙДЕ 12 ЛЕКЦИИ 1



нелинейность у Qwen3 это SiLU, родственник ReLU

Стопка слоёв



У Qwen3-0.6B двадцать восемь слоев.

На каждом токен снова смотрит на соседей, но соседи уже вобрали в себя свое окружение. С каждым слоем контекст дальше и переработаннее.

Первые слои ловят грамматику, последние смысл.

Выход одного слоя это вход следующего. Токен собирает себя из соседей двадцать восемь раз подряд.

Вход и выход

текст

↓

токены

↓

эмбеддинги + позиции

↓

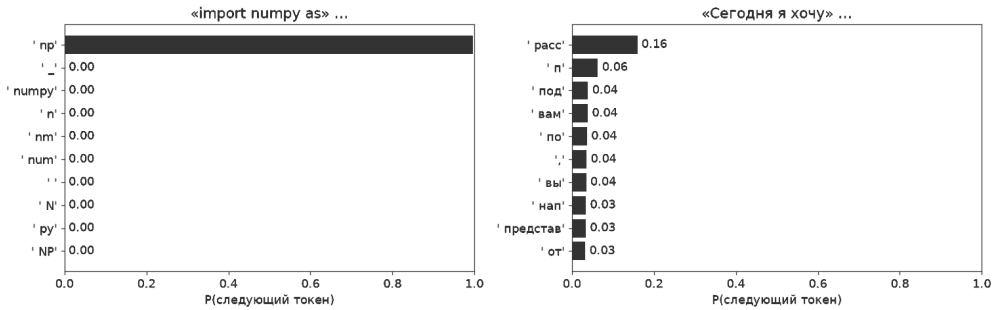
28 слоев: внимание + полносвязная сеть

↓

softmax по словарю для последнего токена

↓

распределение следующего токена



тот же выход, что в демо первой лекции

Та же таблица биграмм из лабораторной №1, только вместо одного предшественника весь контекст.

Модель — семейство распределений.

Обучение — выбор члена семейства, при котором данные наиболее правдоподобны.

Дальше меняется только богатство семейства и масштаб данных.

Все матрицы всех слоев это параметры. У Qwen3-0.6B их 600 миллионов, подбираются так, чтобы тексты были наиболее правдоподобны. Как именно, лекция 3.

ДЕМО

Внимание это не метафора, веса можно посмотреть

1

На кого смотрит «его»

«Врач осмотрел пациента и сказал, что его анализы готовы». Перебираем слои и головы: слой 3, голова 3 отдает 0.73 внимания на «пациента». Этому модель никто не учил.

2

Чем заняты головы

Несколько голов одного слоя рядом: одна смотрит на предыдущее слово, другая на начало, третья на повтор. Специализация возникает сама.

3

Сколько достается инструкции

Инструкция в начале, за ней 128, 512, 1024 токена текста. Доля внимания последнего токена на инструкцию: 0.021, 0.009, 0.003. Это размывание.

Потеря требования на длинной задаче

Требование: в конце каждого ответа пиши слово КОНЕЦ

тысячи токенов: код, документы, вывод инструментов

Ответ без КОНЕЦ. Без отказа, без оговорок, буднично.

СЛУЧАЙ

Требование в начале, длинная работа, в конце требование тихо нарушено. Каждый ответ выглядит правильным.

В ЧЕМ ОШИБКА

Модель не отказалась и не ошиблась явно. Она перестала учитывать то, что было далеко.

МЕХАНИЗМ, ДВА

Размывание: доли в сумме единица, инструкции достается 0.021, потом 0.009, потом 0.003.

Обрезка: контекст не влез, старое отрезано или пересказано. Пересказ по цепочке со слайда 10.

Скриншота поломки нет

Требование явное

и проверяемое глазами: «пиши по-русски», «ставь слово КОНЕЦ». Не «будь аккуратнее».

Контекст заметный

между постановкой и нарушением тысячи токенов, иначе это обычная ошибка.

Нарушение будничное

без отказа и возражений: модель просто сделала иначе.

Требование не противоречивое

если в середине появилось то, что ему противоречит, модель права.

Идеальный кадр: повторили требование, и модель снова его соблюдает. Шаблон cases/protocol_template.md.

ВЫВОД

Важное повторяют и держат близко к концу. Длинную задачу режут на короткие с явным состоянием.

Лабораторная 2: трансформер руками

ТЗ в репозитории, папка assignments/02. Корпус тот же, модели Qwen3-0.6B-Base и e5-small.

Свой BPE

Алгоритм со слайда 5 на «Войне и мире». Для понимания, в курсовую не поедет.

Токены и бюджет

Токенизатор Qwen3, числа со слайда 6 своими руками. Функция count_tokens остается для сервиса.

Поиск по абзацам

Три способа: таблица эмбеддингов, выход последнего слоя, энкодер e5. Recall@5. Функция search остается для RAG.

Внимание

Карта для местоимения и кривая размывания, те же, что на демо.

Три части из четырех заберете в курсовую. С этой работы включается CI: зеленая галочка у коммита. Если репозиторий создан раньше, то в README написано, что нужно сделать.

Для любознательных

lectures/02/why-attention.md

Матрицы и размерности: что такое Q, K, V на самом деле

Скалярное произведение и откуда корень из d

Маска как минус бесконечность и откуда растет кэш

Головы, остаточные связи, нормализация, SwiGLU

Позиционные кодировки: почему RoPE это поворот

Квадратичная цена и где лежат 600 миллионов параметров

На лекции не нужно, на экзамене пригодится.

Спасибо

СЛЕДУЮЩАЯ ЛЕКЦИЯ

Обучение языковых моделей: как подбирают 600 миллионов параметров, энкодеры и декодеры, законы масштабирования.

github.com/pmenshih/tgo-course

Материалы, ноутбуки демонстраций, задания лабораторных, шаблон протокола поломки